R

Appunti di Calcolo Numerico

Università di Pisa - Ingegneria dell'energia AA 25/26

Contents

Ch. 1 **Problemi numerici e stabilità** 3

1.1 Problemi numerici 3

1.2 Problemi stabili e malcondizionati 3

1.2.1 Numero di Condizionamento 4

1.3 Metodi numerici 5

Ch. 2 **Metodi diretti per la soluzione di sistemi lineari** 8

2.1 Introduzione 8

2.2 Metodi diretti per la soluzione di sistemi lineari 11

2.2.1 Matrici elementari 11

2.2.2 Fattorizzazione di matrici 16

2.3 Metodo di eliminazione di Gauss - Fattorizzazione LU . . . 18

2.3.1 Pivoting parziale e totale 21

2.3.2 Fattorizzazione di Gauss Jordan 23

2.4 Metodo di Householder - Fattorizzazione QR 23

Ch. 3 **Metodi iterativi per la soluzione di sistemi lineari** 27

Appendice 28

Prefazione

Gli appunti di calcolo numerico sono stati redatti durante il corso di Calcolo Numerico tenuto dal Prof.L. Heltai e C. Pagliantini presso l'Università di Pisa nell'anno accademico 2025/2026.

Gli appunti vogliono essere un testo chiaro e di immediata comprensione e consultazione, non intende sostituire un testo di riferimento, ma piuttosto essere un complemento ad esso, fornendo spiegazioni dettagliate, ma semplici ed intuitive ed esempi pratici per facilitare la comprensione dei concetti trattati durante il corso.

Nella stesura degli appunti, sono stati utilizzati come riferimento anche i libri di testo consigliati dal docente, in particolare:

- D. Bini, M. Capovani, O. Menchi, *Metodi numerici per l'algebra lineare*, Zanichelli.
- R. Bevilacqua, O. Menchi, *Appunti di calcolo numerico*, https://pages.di.unipi.it/bevilacq/Dispensa11-12.pdf.

Gli appunti sono in fase di scrittura e vengono aggiornati quasi giornalmente, per cui è possibile che alcune sezioni siano ancora incomplete o in fase di revisione.

Pregherei chiunque abbia suggerimenti, correzioni o integrazioni da proporre di farmelo sapere, in modo da poter migliorare ulteriormente la qualità degli appunti.

Grazie a tutti per la collaborazione e buono studio!

Introduzione

Per studiare un "fenomeno", sia esso naturale quale il moto di un pianeta o sia esso un prodotto umano quale il propagarsi dell'inquinamento atmosferico o la costruzione di un ponte, la matematica fornisce strumenti per realizzare ed analizzare dei *modelli* che descrivono, tenendo conto delle varie *approssimazioni*, il fenomeno stesso.

Generalmente un modello matematico è un *modello continuo* (di solito un sistema di equazioni differenziali) che consente di individuare le proprietà qualitative della soluzione, come esistenza, unicità, regolarità, ecc., ma spesso non permette di determinare analiticamente la soluzione. É perciò necessario effettuare un'ulteriore approssimazione sostituendo il modello continuo con un *modello discreto* (processo di discretizzazione).

É ovvio che nella discretizzazione si introducono degli *errori* dovuti principalmente a due fattori:

- **Rappresentazione dei dati**: i calcolatori rappresentano i numeri con un numero finito di cifre.
- **Operazioni aritmetiche**: le operazioni aritmetiche sui numeri rappresentati con un numero finito di cifre introducono errori di arrotondamento.

Gli errori di rappresentazione dei dati e gli errori prodotti dalle singole operazioni si propagano nel corso dei calcoli e generano nella soluzione effettivamente calcolata degli errori che vengono chiamati rispettivamente *errore inerente* ed *errore algoritmico*.

CHAPTER 1

PROBLEMI NUMERICI E STABILITÀ

1.1 PROBLEMI NUMERICI

Un problema numerico è un problema matematico in cui i dati sono espressi mediante numeri (o vettori di numeri) e la soluzione cercata è anch'essa un numero (o un insieme finito di numeri) che soddisfa una certa relazione o condizione specificata, come per esempio un'equazione, una condizione di equilibrio, un sistema di equazioni, una condizione di massimo o minimo, oppure una proprietà di congruenza o proporzionalità.

Definition 1.1 : Problema Diretto.
Il problema diretto consiste nel calcolare la soluzione (x) di una funzione F dato un set di dati specifico ($d \epsilon D$), in simboli:

$$trova\, x \mid F(x,d) = 0 \quad x, d\, \epsilon\, \mathbb{R}^n$$

1.2 PROBLEMI STABILI E MALCONDIZIONATI

Esistono problemi tali che, qualunque algoritmo venga utilizzato per risolverli, l'errore generato nel risultato risulta elevato e tale da rendere privo di significato il risultato stesso.
Per questi problemi, detti *malcondizionati*, piccole variazioni nei dati inducono grosse variazioni nei risultati.

Definition 1.2 : Stabilità.
Si consideri un generico problema diretto. Sia δ_d una perturbazione nei dati e δ_x la corrispondente variazione nella soluzione, tale che:

$$F(x + \delta_x, d + \delta_d) = 0$$

allora il problema è detto stabile se:

$$\exists k_0(d) \in \mathbb{R}^n : \|\delta_x\| \leq k_0(d)\|\delta_d\|$$

dove $k_0(d)$ è una costante che non dipende da δ_d o δ_x.
Si parla di stabilità relativa se:

$$\exists k_0(d) \in \mathbb{R}^n : \frac{\|\delta_x\|}{\|x\|} \leq k_0(d) \frac{\|\delta_d\|}{\|d\|}$$

1.2.1 Numero di Condizionamento

Definiamo ora il concetto di numero di condizionamento.

Questo, altro non è che una misura della sensibilità del problema alle perturbazioni nei dati.

Definition 1.3 : Numero di Condizionamento.
Si consideri un generico problema diretto con $x \neq 0$ e $d \neq 0$. Definiamo:

- $K_{abs}(d)$: numero di condizionamento assoluto del problema.

$$K_{abs}(d) = \sup \left\{ \frac{\|\delta_x\|}{\|\delta_d\|}; \delta_d \neq 0 \right\}$$

- $K(d)$: numero di condizionamento relativo del problema.

$$K(d) = \sup \left\{ \frac{\|\delta_x\|}{\|x\|} \frac{\|d\|}{\|\delta_d\|}; \delta_d \neq 0 \right\}$$

Exercise 1.1. *Esempio di calcolo del numero di condizionamento per un problema specifico: Supponiamo di avere un problema diretto definito da una funzione $F(x, d) = 0$ dove:*

$$F(x, d) = x - (d_1 + d_2) = 0$$

Adottando sul nostro spazio la norma $\|\cdot\|_{l_1}$ dimostra che il numero di condizionamento relativo del problema è $K(d) = 1$.

Observation . *La norma $\|\cdot\|_{l_1}$ nell'esempio agisce sia su $x \epsilon \mathbb{R}$ che su $d \epsilon \mathbb{R}^2$.*

Se la soluzione (x) di un generico problema diretto esiste ed è unica, allora:

$$\exists! G(d) = x \qquad \text{tale che } F(G(d), d) = 0$$

Dove G è un'applicazione detta risolvente del problema diretto.

In questo caso esiste una relazione diretta tra il numero di condizionamento del problema e la derivata della risolvente.

THEOREM 1.1 . Dato un generico problema diretto con soluzione unica e risolvente G supposta continua e derivabile, allora:

$$K(d) \leq \|G'(d)\| \frac{\|d\|}{\|G(d)\|}$$

Il numero di condizionamento assoluto del problema è invece dato da:

$$K_{abs}(d) \approx \|G'(d)\|$$

● **Observation .** *Il teorema precedente fornisce un criterio pratico per stimare il numero di condizionamento di un problema diretto a partire dalla derivata della sua risolvente, che nella maggior parte dei casi risulta più semplice da calcolare o approssimare rispetto al numero di condizionamento stesso.*

Questa relazione è anche coerente con l'intuizione: la derivata misura proprio la sensibilità della soluzione rispetto a piccole variazioni dei dati, ed è quindi naturale che sia strettamente legata al numero di condizionamento del problema.

Proof. Supponendo che G sia continua e derivabile si ha:

$$x + \delta_x = G(d + \delta_d) = G(d) + G'(d)\delta_d + o(\|\delta_d\|); \quad \delta_d \to 0$$

da cui:

$$\delta_x = G(d + \delta_d) - x = G(d + \delta_d) - G(d) \approx G'(d)\delta_d + o(\|\delta_d\|)$$

e quindi:

$$k(d) = \frac{\|\delta_x\|}{\|x\|} \frac{\|d\|}{\|\delta_d\|} \approx \frac{\|G'(d)\delta_d\|}{\|x\|} \frac{\|d\|}{\|\delta_d\|} \leq \|G'(d)\| \frac{\|d\|}{\|x\|}$$

Dove nell'ultimo passaggio abbiamo utilizzato la disuguaglianza di Schwartz della norma.

L'approssimazione del numero di condizionamento assoluto segue da un ragionamento analogo. □

1.3 METODI NUMERICI

Come abbiamo già osservato, non è sempre possibile risolvere analiticamente un problema matematico.

Per questo motivo, introduciamo il concetto di metodo numerico.

Definition 1.4 : Metodo numerico.
Un metodo numerico è una procedura di calcolo che serve a trovare una soluzione approssimata di un problema matematico, soprattutto quando la soluzione esatta è difficile o impossibile da ottenere in forma analitica.
Un metodo numerico consiste in una successione di problemi approssimati:

$$(1)_n \quad F_n(x_n, d_n) = 0$$

con $d_n \to d$ e F_n *approssima* F quando $n \to \infty$.

La nostra speranza è che, risolvendo i problemi approssimati, si riesca ad ottenere una successione di soluzioni approssimate x_n che converga alla soluzione esatta x del problema diretto originale.

Definition 1.5 : Convergenza di un metodo numerico.
Un metodo numerico è detto convergente se l'errore e_n associato al metodo tende a zero quando n tende all'infinito, ovvero se:

$$\lim_{n\to\infty} e_n = \lim_{n\to\infty} \|x_n - x\| = 0$$

Attenzione. Da qui in poi supporremo di avere sempre a che fare con problemi diretti stabili e metodi numerici convergenti, altrimenti i risultati che otterremo potrebbero non essere validi.

Definition 1.6 : Consistenza di un metodo numerico.
Un metodo numerico è detto consistente se:

$$\lim_{n\to\infty} F_n(x, d) = F(x, d)$$

per ogni x e $d \in \mathbb{D}_n$.

Observation . *La consistenza di un metodo numerico ci assicura che l'errore di approssimazione tra l'operatore continuo originale F e l'operatore discreto e approssimato F_n tende a zero quando n tende all'infinito:*

$$\lim_{n\to\infty} \|F_n(x, d) - F(x, d)\| = \|F_n(x, d)\| = 0$$

In altre parole, la consistenza ci garantisce che il metodo numerico stia effettivamente approssimando il problema originale in modo sempre più accurato.

Definition 1.7 : Metodo fortemente consistente.
Un metodo numerico è detto fortemente consistente se:

$$\|F_n(x,d) - F(x,d)\| = O(\|x_n - x\|)$$

Observation (Idea intuitiva). *La quantità*

$$r_n(x,d) := F_n(x,d) - F(x,d)$$

misura il difetto di modello introdotto dalla discretizzazione.

Dire che il metodo è fortemente consistente significa che questo difetto non è "più grande" dell'errore sulla soluzione:

$$\|r_n(x,d)\| \leq C\,\|x_n - x\| \qquad (n \text{ grande})$$

per una costante $C > 0$ indipendente da n.

In parole semplici: quando x_n si avvicina a x, anche l'errore di consistenza si riduce almeno con lo stesso ordine. Quindi la discretizzazione è sufficientemente fedele al problema continuo e non "rovina" la qualità dell'approssimazione numerica.

Introduciamo ora un teorema il cui contenuto è intuitivo e del quale solvoleremo la dimostrazione.

THEOREM 1.2 : Teorema di Lax-Richtmyer (o Teorema di equivalenza)
. Se un metodo numerico di un problema stabile è consistente, allora è convergente:

$$\text{consistenza} \leftrightarrow \text{convergenza}$$

Chapter 2

Metodi diretti per la soluzione di sistemi lineari

2.1 Introduzione

Un sistema lineare è un particolare tipo di problema diretto in cui la funzione F è definita come:

$$F(x, d) = Ax - d$$

con $A \in \mathbb{R}^{n \times n}, x, d \in \mathbb{R}^n$.

I metodi risolutivi per i sistemi lineari sono suddivisibili in due macro-categorie:

- Metodi diretti: forniscono la soluzione esatta in un numero finito di operazioni.
  Sono metodi stabili, ma hanno un costo computazionale elevato.

  Esempi: eliminazione di Gauss, fattorizzazione LU, fattorizzazione Cholesky.

- Metodi iterativi:non calcola la soluzione direttamente in un unico passo, ma costruisce una successione di approssimazioni che si avvicinano sempre più alla soluzione esatta.
  Sono metodi più efficienti dal punto di vista computazionale, ma possono essere instabili e non garantire la convergenza.

  Esempi: metodo di Jacobi, metodo di Gauss-Seidel, metodo del gradiente coniugato.

In ogni caso però, per entrambe le categorie, non si può prescindere dagli errori di rappresentazione e dalla loro propagazione nei calcoli.

Ad ogni modo noi ci concentreremo sullo studio dei metodi diretti.

Come ci si può aspettare, la sensibilità di un problema diretto alle perturbazioni nei dati è strettamente legata alla matrice A che definisce il sistema lineare.

Quando in futuro cercheremo di misurare la sensibilità di un sistema lineare, ci riferiremo al seguente teorema:

THEOREM 2.1 : Numero di condizionamento di un sistema lineare .
Data una norma $\|\cdot\|$ su $\mathbb{R}^n$, sia $\|\cdot\|_m$ la norma indotta su $\mathbb{R}^{n\times n}$.
Si consideri un sistema lineare $Ax = b$ con A invertibile.
Il numero di condizionamento del sistema $Ax = b$ è definito come:

$$K(A) = \|A\|_m \|A^{-1}\|_m$$

Proof. Dimostriamo che $K(A)$ è una misura della sensibilità del sistema alle perturbazioni nei dati. Consideriamo una perturbazione δb nei dati b e la corrispondente variazione δx nella soluzione x. Abbiamo:

$$A(x + \delta x) = b + \delta b$$

Sostituendo $Ax = b$, otteniamo:

$$A\delta x = \delta b$$

Moltiplicando entrambi i lati per A^{-1}, otteniamo:

$$\delta x = A^{-1}\delta b$$

Prendendo le norme, otteniamo:

$$\|\delta x\| \leq \|A^{-1}\|_m \|\delta b\|$$

D'altra parte, abbiamo anche:

$$\|b\| = \|Ax\| \leq \|A\|_m \|x\|$$

Combinando queste due disuguaglianze, otteniamo:

$$\frac{\|\delta x\|}{\|x\|} \leq K(A) \frac{\|\delta b\|}{\|b\|}$$

□

● **Observation .** *Per semplicità abbiamo perturbato il vettore noto b (δ_b), ma è possibile perturbare anche la matrice A (δ_A) e ottenere risultati simili.*

Noi ci concentreremo sullo studio di sistemi definiti da matrici A che sono non singolari (invertibili).

Vengono ora presentate alcune definizioni di sistemi lineari e dei metodi diretti per la loro risoluzione.

Definition 2.1 : Matrici diagonali.

Consideriamo un sistema lineare $Ax = b$ in cui A è una matrice diagonale, ovvero:

$$A = \begin{bmatrix} a_{11} & 0 & \cdots & 0 \\ 0 & a_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_{nn} \end{bmatrix}$$

In questo caso, la soluzione del sistema è immediata e data da:

$$x_i = \frac{b_i}{a_{ii}} \quad \text{per } i = 1, 2, \ldots, n$$

Definition 2.2 : Matrici triangolari.

Consideriamo un sistema lineare $Ax = b$ in cui A è una matrice triangolare superiore, ovvero:

$$A = U = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ 0 & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_{nn} \end{bmatrix}$$

In questo caso, la soluzione del sistema può essere trovata tramite il metodo di sostituzione all'indietro (*backward solve*), ovvero:

$$x_n = \frac{b_n}{a_{nn}}, \quad x_i = \frac{b_i - \sum_{j=i+1}^{n} a_{ij} x_j}{a_{ii}}$$

Nel caso di una matrice triangolare inferiore, si utilizza invece il metodo di sostituzione in avanti (*forward solve*).

$$A = L = \begin{bmatrix} a_{11} & 0 & \cdots & 0 \\ a_{21} & a_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix} \qquad x_1 = \frac{b_1}{a_{11}}, \quad x_i = \frac{b_i - \sum_{j=1}^{i-1} a_{ij} x_j}{a_{ii}}$$

● **Observation .** *Nei prossimi paragrafi verranno utilizzate nuovamente le notazioni U e L per indicare rispettivamente una matrice triangolare superiore (dall'inglese "upper*

triangular") e una matrice triangolare inferiore (dall'inglese "lower triangular").

2.2 METODI DIRETTI PER LA SOLUZIONE DI SISTEMI LINEARI

Molti dei metodi numerici diretti utilizzano per la risoluzione dei sistemi lineari una fattorizzazione della matrice A nel prodotto di due matrici B e C:

$$A = BC$$

La soluzione del sistema viene trovata risolvendo in successione i due sistemi lineari ausiliari:

$$Ax = b \quad \Leftrightarrow \quad By = b,\ Cx = y$$

Fattorizzazioni diverse della matrice A sono associate a metodi risolutivi diversi.
Noi vedremo le seguenti fattorizzazioni:

1. Fattorizzazione LU:
$$A = LU$$
dove L è una matrice triangolare inferiore e U è una matrice triangolare superiore.

2. Fattorizzazione Cholesky:
$$A = LL^T$$
dove L è una matrice triangolare inferiore. Questa fattorizzazione è applicabile solo se A è simmetrica e definita positiva.

3. Fattorizzazione QR:
$$A = QR$$
dove Q è una matrice unitaria e R è una matrice triangolare superiore.

● **Observation .** *La lettera R è spesso utilizzata per indicare una matrice triangolare superiore perchè è sinonimo in inglese di right (una matrice triangolare superiore è sempre una matrice quadrata e ha elementi non nulli solo nella parte destra).*

2.2.1 Matrici elementari

In questo paragrafo si introduce un particolare tipo di matrice, la matrice elementare, che sarà fondamentale nello studio delle fattorizzazioni.

Definition 2.3 : Matrice elementare.
Siano $\sigma \epsilon \mathbb{R}$ e $u, v \in \mathbb{R}^n$ con $u, v \neq 0$. La matrice elementare E è definita come:

$$E = I - \sigma u v^T$$

La classe delle matrici elementari non singolari (ovvero invertibili) è chiusa rispetto all'operazione di inversione.
Vale infatti il seguente teorema.

THEOREM 2.2 : Inversione di una matrice elementare . Ogni matrice elementare, $E(\sigma, u, v)$, per cui valga la condizione:

$$\mathbf{v}^t \mathbf{u} \neq \frac{1}{\sigma}$$

è invertibile e la sua matrice inversa è sempre una matrice elementare della forma:

$$E(\tau, u, v) \quad \text{con} \quad \tau \in \mathbb{R}$$

Proof. Se $\sigma = 0$ la tesi è ovvia, in quanto $E(0, u, v) = I$.

Supponiamo ora $\sigma \neq 0$. Vogliamo dimostrare che esista $\tau \in \mathbb{R}$ tale che:

$$E(\sigma, u, v)E(\tau, u, v) = I$$

Sviluppando il prodotto:

$$(I - \sigma u v^T)(I - \tau u v^T) = I - \sigma u v^T - \tau u v^T + \sigma\tau(u v^T)(u v^T)$$

Poiché $(u v^T)(u v^T) = u(v^T u)v^T = (v^T u)u v^T$, otteniamo:

$$I - (\sigma + \tau)u v^T + \sigma\tau(v^T u)u v^T$$

Per ottenere l'identità, dobbiamo avere:

$$-(\sigma + \tau) + \sigma\tau(v^T u) = 0$$

Da cui si ottiene che τ deve soddisfare la condizione:

$$\mathbf{v}^t \mathbf{u} = \frac{1}{\sigma} + \frac{1}{\tau} \tag{2.1}$$

Da cui la condizione:

$$v^t u \neq \frac{1}{\sigma}$$

□

Introduciamo ora un'altra importante proprietà delle matrici elementari, ovvero la loro capacità di trasformare un vettore in un altro.
Assegnati comunque due vettori non nulli, esiste sempre una matrice elementare non singolare che trasforma il primo vettore nel secondo. Vale infatti il seguente teorema.

THEOREM 2.3 . Siano $x, y \in \mathbb{R}^n$ due vettori non nulli. Allora esiste sempre una matrice elementare non singolare $E(\sigma, u, v)$ t.c.:

$$E(\sigma, u, v)x = y$$

Proof. La condizione $E(\sigma, u, v)x = y$ è equivalente a:

$$(I - \sigma u v^t)x = y$$

Sviluppando:

$$x - \sigma u(v^t x) = y$$

Da cui:

$$\sigma u(v^t x) = x - y$$

Scegliendo $u = x - y$ e $v = x$, otteniamo:

$$\sigma(x - y)(v^t x) = x - y$$

Da cui:

$$\sigma = \frac{1}{v^t x} = \frac{1}{x^t x}$$

□

Due classi di matrici elementari particolarmente importanti per i nostri scopi sono:

- Matrice elemenentare di Gauss: è una matrice elementare della forma:

  $$M = (\sigma, u, e_1) \quad per\, cui: \; Mx = x_1 e_1$$

  in cui $x \in \mathbb{R}^n$, *con* $x_1 \neq 0$.

  La matrice elementare di Gauss è quindi utilizzata per annullare le componenti di un vettore, ad eccezione della prima.

Possiamo pensare alla matrice come:

$$M = \begin{pmatrix} 1 & & & \\ -m_{21} & 1 & & \\ \vdots & & \ddots & \\ -m_{n1} & & & 1 \end{pmatrix} \qquad m_{i1} = \frac{x_i}{x_1} \; per \; i = 2, 3, \ldots, n$$

La matrice elementare di Gauss è sempre invertibile e la sua matrice inversa è anch'essa una matrice elementare di Gauss, ovvero:

$$M^{-1} = (\sigma, -u, e_1) = \begin{pmatrix} 1 & & & \\ m_{21} & 1 & & \\ \vdots & & \ddots & \\ m_{n1} & & & 1 \end{pmatrix}$$

- Matrice elementare di Householder: è una matrice elementare della forma:

$$P = (\beta, \mathbf{v}, \mathbf{v})$$

con $\mathbf{v} \in \mathbb{R}^n$ e $\beta \in \mathbb{R}$ scelti in modo tale che la matrice P sia *unitaria* ($P^{-1} = P^t \; e \; \det(P) = 1$).

Dal teorema (2.2), si ha che P è invertibile se e solo se la condizione $\beta \mathbf{v}^t \mathbf{v} \neq 1$ è soddisfatta.

Inoltre dato che $P^{-1} = P^t$, si ha che:

$$P^{-1} = P^t = (I - \beta \mathbf{v}\mathbf{v}^t)^t = I - \beta(\mathbf{v}\mathbf{v}^t)^t = I - \beta \mathbf{v}\mathbf{v}^t = P$$

Le matrici di Householder sono anche dette *"riflessioni di Householder"* perchè rappresentano una riflessione rispetto al piano ortogonale al vettore $\mathbf{v}$.

Infatti, si consideri $\mathbf{w}$ il versore di $\mathbf{v}$, ovvero $\mathbf{w} = \frac{\mathbf{v}}{\|\mathbf{v}\|}$ ed $\mathbf{x} \in \mathbb{R}^n$ un vettore qualsiasi. Dalla condizione (2.1) su β si ha:

$$P = I - \beta \mathbf{v}\mathbf{v}^t = I - 2\frac{\mathbf{v}^t \mathbf{v}}{\|\mathbf{v}\|^2} = I - 2\mathbf{w}\mathbf{w}^t$$

Siano ora $\gamma \in \mathbb{R}$ e $\mathbf{y} \in S^\perp$ (con S lo spazio generato da $\mathbf{w}$) scelti in modo tale che:

$$x = \gamma \mathbf{w} + \mathbf{y}$$

Si ottiene:

$$P\mathbf{x} = (I - 2\mathbf{w}\mathbf{w}^t)(\gamma\mathbf{w} + \mathbf{y}) = \gamma\mathbf{w} + \mathbf{y} - 2\gamma\mathbf{w}(\mathbf{w}^t\mathbf{w}) - 2\mathbf{w}(\mathbf{w}^t\mathbf{y})$$

Sfruttando la perpendicolarità di $\mathbf{w}$ rispetto a $S^\perp$ ($< \mathbf{w}, \mathbf{y} >= \mathbf{w}^t\mathbf{y} = 0$), si ha:

$$\gamma\mathbf{w} + \mathbf{y} - 2\gamma\mathbf{w}(\mathbf{w}^t\mathbf{w}) - 2\mathbf{w}(\mathbf{w}^t\mathbf{y}) = -\gamma\mathbf{w} + \mathbf{y} \tag{2.2}$$

La figura (2.1) ci mostra graficamente che il vettore dell'equazione (2.2) rappresenta la riflessione del vettore x rispetto ad $S^\perp$.

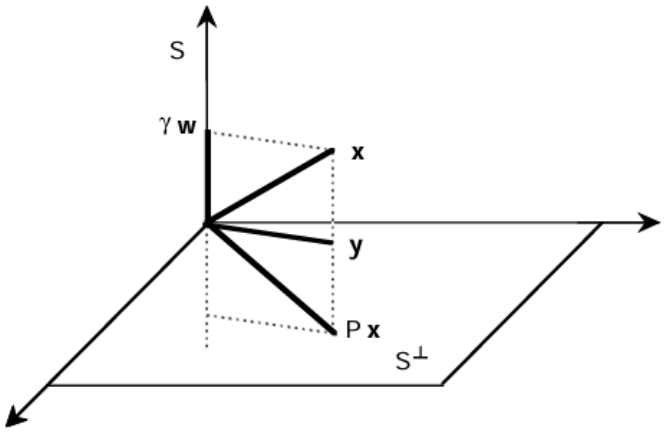

Figure 2.1: Riflessione del vettore x rispetto ad $S^\perp$

Come abbiamo visto, le matrici di Householder rappresentano una riflessione rispetto al piano ortogonale al vettore $\mathbf{v}$. Quindi, dato un vettore $\mathbf{x}$, è sempre possibile costruire una matrice di Householder che riflette $\mathbf{x}$ in un vettore parallelo a $\mathbf{e}_1$ ed arrivare in modo intuitivo alla tesi del seguente teorema.

THEOREM 2.4 . Per ogni vettore $\mathbf{x} \in \mathbb{R}^n$, con $\mathbf{x} \neq 0$, si può identificare una matrice di Householder tale che:

$$P\mathbf{x} = \alpha\mathbf{e}_1 \quad con \quad \alpha \in \mathbb{R}$$

Dove α rappresenta una costante opportuna e:

$$\mathbf{v} = \mathbf{x} - \alpha\mathbf{e}_1, \quad \beta = \frac{2}{\|\mathbf{v}\|^2}$$

Proof. Vogliamo costruire esplicitamente $\mathbf{v}$ e β tali che $P = I - \beta\mathbf{v}\mathbf{v}^t$ soddisfi $P\mathbf{x} =$

$\alpha \mathbf{e}_1$.

Passo 1: determinazione di α. Poiché P è unitaria ($P^t P = I$), essa preserva la norma euclidea:

$$\|\mathbf{x}\| = \|P\mathbf{x}\| = \|\alpha \mathbf{e}_1\| = |\alpha|.$$

Quindi necessariamente $|\alpha| = \|\mathbf{x}\|$. Per evitare cancellazione numerica nella scelta di $\mathbf{v}$, si sceglie α con segno *opposto* alla prima componente x_1 di $\mathbf{x}$:

$$\alpha = -\operatorname{sgn}(x_1)\,\|\mathbf{x}\|, \qquad \text{con} \quad \operatorname{sgn}(x_1) = \begin{cases} \dfrac{x_1}{|x_1|} & \text{se } x_1 \neq 0 \\ 1 & \text{se } x_1 = 0. \end{cases}$$

Passo 2: scelta di v. La condizione $P\mathbf{x} = \alpha \mathbf{e}_1$ si riscrive come:

$$(I - \beta \mathbf{v}\mathbf{v}^t)\mathbf{x} = \alpha \mathbf{e}_1 \quad \Longrightarrow \quad \beta\,(\mathbf{v}^t\mathbf{x})\,\mathbf{v} = \mathbf{x} - \alpha \mathbf{e}_1.$$

Questa equazione è soddisfatta scegliendo:

$$\mathbf{v} = \mathbf{x} - \alpha \mathbf{e}_1.$$

Notiamo che $\mathbf{v} \neq \mathbf{0}$: se fosse $\mathbf{v} = \mathbf{0}$, allora $\mathbf{x} = \alpha \mathbf{e}_1$ con $\alpha = -\operatorname{sgn}(x_1)\|\mathbf{x}\|$, ma questo implicherebbe $x_1 = \alpha = -|x_1|$, cioè $|x_1| = 0$, contraddizione con $\mathbf{x} \neq \mathbf{0}$.

Passo 3: determinazione di β. Con la scelta $\mathbf{v} = \mathbf{x} - \alpha \mathbf{e}_1$ si calcola:

$$\mathbf{v}^t\mathbf{x} = (\mathbf{x} - \alpha \mathbf{e}_1)^t\mathbf{x} = \|\mathbf{x}\|^2 - \alpha x_1.$$

Osserviamo inoltre che:

$$\|\mathbf{v}\|^2 = \|\mathbf{x} - \alpha \mathbf{e}_1\|^2 = \|\mathbf{x}\|^2 - 2\alpha x_1 + \alpha^2 = 2\|\mathbf{x}\|^2 - 2\alpha x_1 = 2(\mathbf{v}^t\mathbf{x}).$$

Sostituendo nella condizione $\beta(\mathbf{v}^t\mathbf{x})\mathbf{v} = \mathbf{v}$:

$$\beta\,(\mathbf{v}^t\mathbf{x}) = 1 \quad \Longrightarrow \quad \beta = \frac{1}{\mathbf{v}^t\mathbf{x}} = \frac{2}{\|\mathbf{v}\|^2} = \frac{2}{\|\mathbf{x} - \alpha \mathbf{e}_1\|^2}.$$

La matrice $P = I - \beta \mathbf{v}\mathbf{v}^t$ così costruita è quindi la Householder cercata. □

2.2.2 Fattorizzazione di matrici

In questo paragrafo si introduce un teorema fondamentale per la fattorizzazione di matrici quadrate, che sarà alla base di molti metodi diretti per la risoluzione di sistemi lineari.

THEOREM 2.5 : Fattorizzazione di matrici quadrate . Si può sempre fattorizzare una matrice $A \in \mathbb{R}^{n \times n}$ in un prodotto di due matrici E ed U, dove E è un prodotto di matrici elementari e U è una matrice triangolare superiore:

$$A = EU$$

Proof. (per induzione su n)

Sia A una matrice $n \times n$. Pensiamo ad A come ad una matrice $A = A^{(1)}$ composta da una colonna a_1 e da una matrice B composta dalle restanti colonne:

$$A^{(1)} = [a_1 | B]$$

Sia $E^{(1)}$ una matrice elementare non singolare che annulli le componenti di a_1 ad eccezione della prima, ovvero:

$$E^{(1)} a_1 = a_{11} e_1$$

Moltiplicando entrambi i lati per $E^{(1)}$, otteniamo:

$$A^{(2)} = E^{(1)} A^{(1)} = [\mathbf{b_1} | E^{(1)} B]$$

Dove:

$$A^{(2)} = \begin{bmatrix} \alpha & \mathbf{c}^t \\ \mathbf{0} & B^{(2)} \end{bmatrix}$$

Iterando n-1 volte questo processo sulla sottmatrice $B^{(2)}$, otteniamo una successione di matrici $A^{(k)}$ $k = 1, 2, \ldots, n$ tali che:

$$A^{(k)} = \begin{bmatrix} C^{(k)} & D^{(k)} \\ \mathbf{0} & B^{(k)} \end{bmatrix}$$

Dove $C^{(k)} \in \mathbb{R}^{(k-1)\times(k-1)}, D^{(k)} \in \mathbb{R}^{(k-1)\times(n-k+1)}, B^{(k)} \in \mathbb{R}^{(n-k+1)\times(n-k+1)}$. Inoltre ipotizziamo che $C^{(k)}$ sia triangolare superiore e che $B^{(k)}$ sia invertibile.

Prendiamo ora la matrice elementare $F^{(k)} \in \mathbb{R}^{(n-k+1)\times(n-k+1)}$ che annulli le componenti della prima colonna di $B^{(k)}$ ad eccezione della prima, ovvero:

$$F^{(k)} B^{(k)} = \begin{bmatrix} \beta & \mathbf{d}^t \\ \mathbf{0} & B^{(k+1)} \end{bmatrix}$$

Definiamo ora la matrice elementare (ne viene evitata la dimostrazione) $E^{(k)}$ come:

$$E^{(k)} = \begin{bmatrix} I_{k-1} & \mathbf{0} \\ \mathbf{0} & F^{(k)} \end{bmatrix}$$

Moltiplicando $E^{(k)}$ per $A^{(k)}$, otteniamo:

$$A^{(k+1)} = E^{(k)}A^{(k)} = \begin{bmatrix} C^{(k)} & D^{(k)} \\ \mathbf{0} & F^{(k)}B^{(k)} \end{bmatrix} = \begin{bmatrix} C^{(k)} & D^{(k)} \\ \mathbf{0} & \begin{bmatrix} \beta & \mathbf{d}^t \\ \mathbf{0} & B^{(k+1)} \end{bmatrix} \end{bmatrix} = \begin{bmatrix} C^{(k+1)} & D^{(k+1)} \\ \mathbf{0} & B^{(k+1)} \end{bmatrix}$$

Dove $C^{(k+1)}$ è ancora triangolare superiore e $B^{(k+1)}$, per il *teorema dei minori e del minimo*, è invertibile. All' $(n-1)$-esimo passo, otteniamo:

$$A^{(n)} = \begin{bmatrix} C^{(n)} & \mathbf{g} \\ \mathbf{0}^t & \gamma \end{bmatrix}$$

Dove $C^{(n)}$ è triangolare superiore e γ è un numero reale diverso da zero e quindi $A^{(n)}$ è una matrice triangolare superiore.

Dato che $E(k)$ è non singolare per ogni $k = 1, 2, \ldots, n-1$, si ha:

$$A = E^{(1)^{-1}} E^{(2)^{-1}} \cdots E^{(n-1)^{-1}} A^{(n)} = EA^{(n)} = EU \quad \textit{con } E \textit{ matrice elementare}$$

Da cui la tesi. □

2.3 Metodo di eliminazione di Gauss - Fattorizzazione LU

Definition 2.4 : Metodo (di eliminazione) di Gauss - Fattorizzazione LU.
Viene detto metodo (di eliminazione) di Gauss o fattorizzazione LU il procedimento descritto nella dimostrazione del teorema (2.5) quando la matrice E è un prodotto di matrici elementari di Gauss, ovvero:

$$E^{(k)} = \begin{bmatrix} I & \mathbf{0} \\ \mathbf{0} & M^{(k)} \end{bmatrix} = \begin{bmatrix} 1 & & & & & \\ & \ddots & & & & \\ & & 1 & & & \\ & & -m_{k+1,k} & 1 & & \\ & & \vdots & & \ddots & \\ & & -m_{nk} & & & 1 \end{bmatrix}$$

Dove $M^{(k)}$ è una matrice elementare di Gauss di ordine $n-k+1$ ($M^{(k)} \in \mathbb{R}^{(n-k+1)\times(n-k+1)}$).

Da cui si trova (ricordando che la classe delle matrici elementari non singolari è chiusa rispetto all'operazione di inversione):

$$L = E^{-1} \dots E^{(n-1)^{-1}} = \begin{bmatrix} 1 & & & & & \\ m_{21} & \ddots & & & & \\ \vdots & \ddots & 1 & & & \\ \vdots & & m_{k+1,k} & \ddots & & \\ \vdots & & \vdots & \ddots & \ddots & \\ m_{n1} & \dots & m_{nk} & \dots & m_{(n-1)n} & 1 \end{bmatrix}$$

dove

$$m_{ik} = \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}$$

con $i = k+1, k+2, \dots, n$ e $k = 1, 2, \dots, n-1$.

EXAMPLE 2.1 : FATTORIZZAZIONE LU DI UNA MATRICE 4×4.

Consideriamo il sistema lineare $Ax = b$ con:

$$A = \begin{bmatrix} -2 & 4 & -1 & -1 \\ 4 & -9 & 0 & 5 \\ -4 & 5 & -5 & 5 \\ -8 & 8 & -23 & 20 \end{bmatrix} \qquad b = \begin{bmatrix} 12 \\ -32 \\ 3 \\ -13 \end{bmatrix}$$

Applichiamo il metodo di Gauss per risolvere il sistema.
Si pone:

$$A^{(1)} = A$$

Si costruiscono le matrici elementari di Gauss $E^{(k)}$.

Primo passo:

$$E^{(1)} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 2 & 1 & 0 & 0 \\ -2 & 0 & 1 & 0 \\ -4 & 0 & 0 & 1 \end{bmatrix}$$

$$A^{(2)} = E^{(1)}A^{(1)} = \begin{bmatrix} -2 & 4 & -1 & -1 \\ 0 & -1 & -2 & 3 \\ 0 & -3 & -3 & 7 \\ 0 & -8 & -19 & 24 \end{bmatrix}$$

Secondo passo:

$$E^{(2)} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & -3 & 1 & 0 \\ 0 & -8 & 0 & 1 \end{bmatrix}$$

$$A^{(3)} = E^{(2)}A^{(2)} = \begin{bmatrix} -2 & 4 & -1 & -1 \\ 0 & -1 & -2 & 3 \\ 0 & 0 & 3 & -2 \\ 0 & 0 & -3 & 0 \end{bmatrix}$$

Terzo passo:

$$E^{(3)} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 1 \end{bmatrix}$$

$$U = A^{(4)} = E^{(3)}A^{(3)} = \begin{bmatrix} -2 & 4 & -1 & -1 \\ 0 & -1 & -2 & 3 \\ 0 & 0 & 3 & -2 \\ 0 & 0 & 0 & -2 \end{bmatrix}$$

Abbiamo quindi ottenuto la fattorizzazione $A = LU$ con:

$$U = \begin{bmatrix} -2 & 4 & -1 & -1 \\ 0 & -1 & -2 & 3 \\ 0 & 0 & 3 & -2 \\ 0 & 0 & 0 & -2 \end{bmatrix}$$

$$L = \begin{bmatrix} 1 & 0 & 0 & 0 \\ -2 & 1 & 0 & 0 \\ 2 & 3 & 1 & 0 \\ 4 & 8 & -1 & 1 \end{bmatrix}$$

Implementando ora la risoluzione dei sistemi lineari ausiliari $Ly = b$ e $Ux = y$, otteniamo:

$$y = \begin{bmatrix} 12 \\ -8 \\ -9 \\ -4 \end{bmatrix} \qquad x = \begin{bmatrix} -1 \\ -2 \\ -3 \\ 2 \end{bmatrix}$$

Dove, ricordando che L ed U sono rispettivamente una matrice triangolare inferiore ed una matrice triangolare superiore, abbiamo utilizzato il metodo di sostituzione in avanti ($forward\,solve$) per risolvere $Ly = b$ e il metodo di sostituzione all'indietro ($backward\,solve$) per risolvere $Ux = y$.

Come si può intuire, non è sempre possibile fattorizzare una matrice A in un prodotto LU senza dover effettuare alcuna "modifica" alla matrice A stessa.

Ad esempio, se la matrice A ha un elemento nullo sulla diagonale principale, risulta evidente che sia impossibile annullare le componenti di una colonna utilizzando una matrice elementare di Gauss, in quanto si avrebbe una divisione per zero:

$$m_{ik} = \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}$$

THEOREM 2.6 : esistenza ed unicità della fattorizzazione LU . Sia $A \in \mathbb{R}^{n \times n}$ una matrice quadrata e siano $A^{(k)}$ le sue sottomatrici principali di testa di ordine k.
Se $A^{(k)}$ è invertibile per ogni $k = 1, 2, \ldots, n-1$, allora esiste ed è unica la fattorizzazione LU di A.

2.3.1 Pivoting parziale e totale

La condizione richiesta dal teorema 2.6 (tutti i minori principali invertibili) è **difficile da verificare a priori**, specialmente per matrici di grande dimensione.

Per questo motivo, nell'implementazione pratica del metodo di Gauss si utilizzano due tecniche dette: pivoting parziale e pivoting totale. Queste strategie garantiscono sempre l'applicabilità della fattorizzazione, evitando divisioni per zero o per numeri troppo piccoli (che amplificano gli errori numerici).

Il concetto è semplice e intuitivo: se l'elemento $a_{kk}^{(k)}$ (pivot) è nullo o molto piccolo, non si può procedere con l'eliminazione. La soluzione naturale consiste nello scambiare righe (e talvolta colonne) per portare un elemento sufficientemente grande in posizione pivot.

Vediamo ora in dettaglio come funzionano e in che modo si differenziano i due metodi.

Definition 2.5 : Pivoting parziale e totale.

- **Pivoting parziale:**

  consiste nell'effettuare una permutazione delle righe di $A^{(k)}$ per portare l'elemento di massimo modulo della colonna k in posizione (k, k).

- **Pivoting totale:**

  consiste nell'effettuare permutazioni sia di righe che di colonne di ogni matrice $A^{(k)}$, scegliendo il massimo assoluto nel blocco $i, j \geq k$.

In simboli (pivoting parziale):

$$A^{(k)} = P_k^{(k)} A^{(k)}$$

dove $P_k^{(k)}$ è la matrice di permutazione che scambia le righe k ed ℓ:

$$(P_{k,\ell})_{ij} = \begin{cases} 1 & \text{se } i = j < k \text{ o } i = j > \ell \\ 1 & \text{se } (i,j) = (k,\ell) \text{ o } (i,j) = (\ell,k) \\ 0 & \text{altrimenti} \end{cases}$$

Alla fine si ottiene la fattorizzazione:

$$\Pi A = LU \quad \textit{con} \quad \Pi = (P_{n-1}^{(n-1)} \cdots P_1^{(1)})^{-1}$$

● **Observation .** *Il simbolo $=$ nella formula $A^{(k)} = P_k^{(k)} A^{(k)}$ è usato in senso "operativo", come nell'informatica.*

Dopo l'applicazione della permutazione $P^{(k)}$, la nuova matrice $A^{(k)}$ ***sostituisce*** *quella precedente nei passi successivi dell'algoritmo.*

È evidente che il **pivoting totale**, dovendo cercare il massimo assoluto nell'intero blocco sottodiagonale, ha un **costo computazionale maggiore** rispetto al pivoting parziale.

Tuttavia, il pivoting totale offre una maggiore garanzia di stabilità numerica, controllando meglio la crescita degli elementi intermedi e riducendo l'amplificazione degli errori di arrotondamento.

2.3.2 Fattorizzazione di Gauss Jordan

Il metodo di Gauss-Jordan costituisce una variante del metodo di Gauss in cui, oltre all'eliminazione degli elementi **sotto** la diagonale principale, si procede anche all'annullamento degli elementi **sopra** la diagonale principale.

Questo processo porta direttamente alla matrice **identità**, trasformando il sistema $Ax = b$ nella forma risolta $x = A^{-1}b$.

Alla fine si ottiene la fattorizzazione:

$$A = LU \quad con \quad U = A^{(n)}$$

Dove $A^{(n)}$ è una matrice diagonale.

● **Observation .** *Solitamente si evita di implementare il metodo di Gauss-Jordan perche'non offre una maggiore stabilità numerica rispetto al metodo di Gauss (oltre ad avere un costo computazionale elevato).*

2.4 Metodo di Householder - Fattorizzazione QR

Come si può intuire, per analogia con il metodo di Gauss, è possibile utilizzare le matrici elementari di Householder per fattorizzare una matrice $A \in \mathbb{R}^{m\times n}$ in un prodotto QR, grazie ai teoremi (2.5) e (2.4).

Definition 2.6 : Metodo di Householder - Fattorizzazione QR.

Viene detto metodo di Householder o fattorizzazione QR il procedimento descritto nella dimostrazione del teorema (2.5) quando la matrice E è un prodotto di matrici elementari di Householder, dove

$$E^{(k)} = \begin{bmatrix} I_{k-1} & \mathbf{0} \\ \mathbf{0} & P^{(k)} \end{bmatrix} = \begin{bmatrix} 1 & & & \\ & \ddots & & \\ & & 1 & \\ & & & P^{(k)} \end{bmatrix}$$

e $P^{(k)}$ è la matrice di Householder di ordine $n-k+1$ che azzera le componenti sotto la diagonale nella k-esima colonna di $A^{(k)}$.

Costruzione esplicita di $P^{(k)}$. La matreice $P^{(k)}$ è costruita seguendo il procedimento descritto nel teorema (2.4), ovvero:

$$P^{(k)} = I - \beta \mathbf{v}\mathbf{v}^t$$

con:

$$\mathbf{v} = \mathbf{x} - \alpha \mathbf{e}_1, \quad \beta = \frac{2}{\|\mathbf{v}\|^2}$$

dove $\mathbf{x}$ è la k-esima colonna di $A^{(k)}$ a partire dalla riga k-esima, $\mathbf{e}_1$ è il primo vettore della base canonica di $\mathbb{R}^{n-k+1}$ e α è scelto come:

$$\alpha = -\operatorname{sgn}(x_1)\,\|\mathbf{x}\|$$

Dato che, per un teorema di algebra lineare, $(AB)^t = B^t A^t$ e dato che $P^{(k)}$ è una matrice unitaria ($P^{(k)^{-1}} = P^{(k)^t}$), si ha che:

$$Q = E^{(1)^{-1}} E^{(2)-1} \cdots E^{(n-1)^{-1}} = E^{(1)^t} E^{(2)^t} \cdots E^{(n-1)^t} = (E^{(n-1)} E^{(n-2)} \cdots E^{(1)})^t$$

è una matrice unitaria e che:

$$R = A^{(n)} = E^{(n-1)} \cdots E^{(2)} E^{(1)} A$$

è una matrice triangolare superiore.

EXAMPLE 2.2 : ESEMPIO DI FATTORIZZAZIONE QR DI UNA MATRICE 3×3.

Consideriamo la matrice:

$$A = \begin{bmatrix} 2 & 1 & 1 \\ 0 & 3 & 1 \\ 0 & 4 & 1 \end{bmatrix}$$

e applichiamo il procedimento della definizione:

$$A^{(1)} = A, \qquad A^{(k+1)} = E^{(k)} A^{(k)}$$

Passo $k = 1$. Si considera la prima colonna di $A^{(1)}$ a partire dalla riga 1:

$$\mathbf{x}^{(1)} = \begin{bmatrix} 2 \\ 0 \\ 0 \end{bmatrix}, \qquad \alpha_1 = -\operatorname{sgn}(2)\,\|\mathbf{x}^{(1)}\| = -2$$

$$\mathbf{v}^{(1)} = \mathbf{x}^{(1)} - \alpha_1 \mathbf{e}_1 = \begin{bmatrix} 4 \\ 0 \\ 0 \end{bmatrix}, \qquad \beta_1 = \frac{2}{\|\mathbf{v}^{(1)}\|^2} = \frac{1}{8}$$

$$P^{(1)} = I - \beta_1 \mathbf{v}^{(1)} \mathbf{v}^{(1)t} = \begin{bmatrix} -1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

Per $k = 1$ vale $E^{(1)} = P^{(1)}$, quindi:

$$A^{(2)} = E^{(1)} A^{(1)} = \begin{bmatrix} -2 & -1 & -1 \\ 0 & 3 & 1 \\ 0 & 4 & 1 \end{bmatrix}$$

Passo $k = 2$**.** Si lavora sulla seconda colonna di $A^{(2)}$ dalla riga 2 in poi:

$$\mathbf{x}^{(2)} = \begin{bmatrix} 3 \\ 4 \end{bmatrix}, \qquad \alpha_2 = -\mathrm{sgn}(3)\, \|\mathbf{x}^{(2)}\| = -5$$

$$\mathbf{v}^{(2)} = \mathbf{x}^{(2)} - \alpha_2 \mathbf{e}_1 = \begin{bmatrix} 8 \\ 4 \end{bmatrix}, \qquad \beta_2 = \frac{2}{\|\mathbf{v}^{(2)}\|^2} = \frac{1}{40}$$

$$P^{(2)} = I - \beta_2 \mathbf{v}^{(2)} \mathbf{v}^{(2)t} = \begin{bmatrix} -\frac{3}{5} & -\frac{4}{5} \\ -\frac{4}{5} & \frac{3}{5} \end{bmatrix}$$

L'estensione a ordine 3 è:

$$E^{(2)} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & -\frac{3}{5} & -\frac{4}{5} \\ 0 & -\frac{4}{5} & \frac{3}{5} \end{bmatrix}$$

$$R = A^{(3)} = E^{(2)} A^{(2)} = \begin{bmatrix} -2 & -1 & -1 \\ 0 & -5 & -\frac{7}{5} \\ 0 & 0 & -\frac{1}{5} \end{bmatrix}$$

Infine, dalla definizione:

$$Q = \begin{bmatrix} -1 & 0 & 0 \\ 0 & -\frac{3}{5} & -\frac{4}{5} \\ 0 & -\frac{4}{5} & \frac{3}{5} \end{bmatrix}$$

con:

$$Q = \left(E^{(2)} E^{(1)}\right)^t$$

e si verifica immediatamente che $Q^t Q = I$ e $A = QR$.

CHAPTER 3

METODI ITERATIVI PER LA SOLUZIONE DI SISTEMI LINEARI

Appendice

A - Richiami di Algebra lineare

B - Rappresentazione in base di un numero, Numeri binari e aritmetica in virgola mobile

Definition 3.1 : Rappresentazione in base di un numero.

Sia $x \in \mathbb{R}$ un numero reale non nullo e sia $\beta \in \mathbb{N} \setminus \{1\}$ un intero detto base. Allora esistono e sono unici un intero $p \in \mathbb{Z}$ (esponente) e una successione di cifre intere d_i, con $0 \leq d_i < \beta$ e $d_1 \neq 0$, tali che:

$$x = sgn(x)\beta^p \sum_{i=1}^{\infty} d_i \beta^{-i}$$

dove $sgn(x)$ è la funzione segno di x, la somma $\sum_{i=1}^{\infty} d_i \beta^{-i}$ è detta mantissa e i coefficienti d_i sono detti cifre della rappresentazione in base β di x.

Example 3.1 : Rappresentazione in base 10.

Il numero 347.25_{10} si può scrivere come

$$347.25 = 3 \cdot 10^2 + 4 \cdot 10^1 + 7 \cdot 10^0 + 2 \cdot 10^{-1} + 5 \cdot 10^{-2}.$$

In questo caso si ha:

- $sgn(347.25) = 1$,
- $p = 3$,
- $d_1 = 3, d_2 = 4, d_3 = 7, d_4 = 2, d_5 = 5$ e $d_i = 0$ per $i > 5$.

Example 3.2 : Rappresentazione binaria.

Il numero 13.625_{10} in base 2 è

$$13.625_{10} = 1101.101_2,$$

poiché

$$1101.101_2 = 1 \cdot 2^3 + 1 \cdot 2^2 + 0 \cdot 2^1 + 1 \cdot 2^0 + 1 \cdot 2^{-1} + 0 \cdot 2^{-2} + 1 \cdot 2^{-3}.$$

Quindi la parte intera e la parte frazionaria sono entrambe espresse con potenze di 2.

Proprio come noi, i calcolatori hanno una capacità di memorizzare informazioni limitata, e non possono quindi rappresentare numeri con un numero infinito di cifre. Per questo motivo, si introduce il concetto di **numeri macchina**.

Definition 3.2 : Numeri di macchina.
Siano $t, L, U \in \mathbb{N}$ con $t \geq 1$ e $0 < L < U$.
Viene definito l'insieme dei numeri di macchina in base β e cifre significative t come:

$$\mathcal{F}(\beta, t, L, U) = \{0\} \cup \{sgn(x)\beta^p \sum_{i=1}^{t} d_i \beta^{-i} : L \leq p \leq U, 0 \leq d_i < \beta, d_1 \neq 0\}$$

Per rendere **unica** la rappresentazione in base di un numero reale, si usa la cosiddetta forma normalizzata.

In questo modo la prima cifra della mantissa e' non nulla e si evitano scritture equivalenti dello stesso numero.

● **Observation .** *La normalizzazione elimina ambiguita' del tipo*

$$0.10 \cdot 10^2 = 0.01 \cdot 10^3,$$

ed e' la convenzione standard nelle definizioni teoriche dell'insieme dei numeri macchina.

Proposition 3.1 (Numero di elementi di $\mathcal{F}(\beta, t, L, U)$). *Fissati base, cifre significative e intervallo degli esponenti, il numero di elementi non nulli e':*

$$2\,(U - L + 1)\,(\beta - 1)\,\beta^{t-1},$$

quindi la cardinalita' dell'insieme dei numeri macchina e':

$$\#\mathcal{F}(\beta, t, L, U) = 1 + 2\,(U - L + 1)\,(\beta - 1)\,\beta^{t-1}.$$

● **Observation** (Conseguenza). *L'insieme dei numeri macchina e' finito; di conseguenza quasi tutti i numeri reali **non** sono rappresentabili esattamente in macchina.*

La rappresentazione in macchina di un numero reale introduce quindi un errore, detto errore di rappresentazione, che dipende, per l'appunto, dalla capacità limitata del calcolatore di rappresentare i numeri reali.

In particolare, se x non e' rappresentabile esattamente, si deve scegliere un numero di macchina ($fl(x)$) che approssimi x alla t-esima cifra significativa, secondo una regola di arrotondamento.

Nella scelta di $fl(x)$, si può incombere in due tipi di problemi.

Definition 3.3 : Overflow e underflow.
Sia $x \neq 0$.

- **overflow**: $|x|$ e' troppo grande per il range di esponenti disponibile;
- **underflow**: $|x|$ e' troppo piccolo e puo' essere approssimato a zero (o a un numero denormalizzato, se previsto dal formato).

Aritmetica in virgola mobile (floating-point)

Definition 3.4 : Aritmetica in virgola mobile.

Si chiama **aritmetica in virgola mobile** l'aritmetica in cui ogni operazione $\circ \in \{+, -, \cdot, /\}$ tra numeri macchina x, y viene eseguita come

$$x \circ_m y = fl(x \circ y),$$

cioe' il risultato reale dell'operazione viene successivamente riportato nel formato di macchina tramite una regola di arrotondamento.